

# 模式识别课程实验汇报

Bayes 分类器、线性判别、K-L 变换、图像识别与聚类分析

姓名：请填写


学号：请填写

班级：请填写

# 汇报思路

|                         |                             |                        |                          |                    |
|-------------------------|-----------------------------|------------------------|--------------------------|--------------------|
| <b>实验一</b><br>Bayes 分类器 | <b>实验二</b><br>非参数估计与 Fisher | <b>实验三</b><br>K-L 特征提取 | <b>实验四</b><br>K-L 图像识别应用 | <b>实验五</b><br>聚类分析 |
|-------------------------|-----------------------------|------------------------|--------------------------|--------------------|

每个实验按照同一条主线展开：



# 数据与实验环境

## 主要数据

| 数据集           | 用途           |
|---------------|--------------|
| FEMALE / MALE | 性别分类、特征提取、聚类 |
| test1 / test2 | 分类器泛化测试      |
| 飞机图像数据集       | K-L 图像识别应用   |

## 实验工具

| 工具            | 作用            |
|---------------|---------------|
| Python 3.11   | 实验主环境         |
| NumPy / SciPy | 数值计算          |
| scikit-learn  | 评估、PCA、层次聚类辅助 |
| Matplotlib    | 结果可视化         |

核心实验代码均已脚本化执行，输出包括指标 CSV、图像结果和 LaTeX 报告。

# 实验一

用身高/体重数据建立 Bayes 性别分类器

# 实验一：课程理论

Bayes 分类器根据后验概率进行决策：

$$\hat{\omega} = \arg \max_{\omega_i} P(\omega_i | \mathbf{x}) = \arg \max_{\omega_i} p(\mathbf{x} | \omega_i) P(\omega_i)$$

在正态分布假设下：

$$g_i(\mathbf{x}) = -\frac{1}{2} \ln |\Sigma_i| - \frac{1}{2} (\mathbf{x} - \mu_i)^T \Sigma_i^{-1} (\mathbf{x} - \mu_i) + \ln P(\omega_i)$$

## 参数估计

最大似然估计均值和协方差

## 先验概率

影响决策边界偏移

## 最小风险


用损失函数代替单纯错误率

# 实验一：实验设置与实现



## 设置

- 训练集：50 个女生、50 个男生
- 测试集：test1 35 个样本，test2 300 个样本
- 特征：身高、体重、身高+体重
- 先验：0.5/0.5、0.75/0.25、0.9/0.1
- 协方差：完整协方差、对角协方差

## 实现流程



# 实验一：数据分布与决策边界



男生样本整体身高、体重更高，但边界区域存在重叠，因此无法做到完全无误分类。

# 实验一： 结果与分析

| 方法                   | 训练集    | test1   | test2  |
|----------------------|--------|---------|--------|
| 二维 Bayes, 完整协方差, 等先验 | 88.00% | 97.14%  | 89.33% |
| 二维 Bayes, 对角协方差, 等先验 | 88.00% | 97.14%  | 90.33% |
| 最小风险 Bayes           | 84.00% | 94.29%  | 84.33% |
| Parzen Bayes         | 87.00% | 97.14%  | 90.33% |
| kNN, k=5             | 89.00% | 100.00% | 90.33% |



# 实验二

非参数估计、Fisher 线性判别与留一法

# 实验二：课程理论

Parzen 窗估计不预设密度形式：

$$\hat{p}(\mathbf{x}|\omega_i) = \frac{1}{N_i} \sum_{k=1}^{N_i} \frac{1}{(2\pi)^{d/2} h^d} \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}_k\|^2}{2h^2}\right)$$

Fisher 线性判别寻找投影方向，使类间离散度相对类内离散度最大：

$$J(\mathbf{w}) = \frac{\mathbf{w}^T S_b \mathbf{w}}{\mathbf{w}^T S_w \mathbf{w}}, \quad \mathbf{w} = S_w^{-1}(\mu_1 - \mu_2)$$

留一法用于在样本较少时估计泛化误差。

# 实验二：实验设置与实现

## Parzen Bayes


高斯核，窗口宽度  $h=5.0$

## Fisher 判别



同时使用身高和体重

## 留一法

每次留出一个训练样本验证



# 实验二：决策边界与投影



Bayes 边界可以是非线性的；Fisher 直接给出线性投影与阈值，解释性更强。

# 实验二： 结果与分析

| 方法             | 训练错误率  | test1 错误率 | test2 错误率 | 留一法错误率 |
|----------------|--------|-----------|-----------|--------|
| Gaussian Bayes | 12.00% | 2.86%     | 10.67%    | 12.00% |
| Parzen Bayes   | 13.00% | 2.86%     | 9.67%     | 14.00% |
| Fisher         | 12.00% | 2.86%     | 9.67%     | 13.00% |

## 分析

- Parzen 不依赖正态分布假设，但对窗口宽度敏感
- Fisher 不估计概率密度，直接优化线性可分性
- 留一法结果与 test2 更接近，说明其能较稳健地估计泛化误差

# 实验三

K-L 变换进行特征提取

# 实验三：课程理论

K-L 变换即 PCA，从协方差矩阵的特征分解中寻找最大方差方向：

$$\Sigma \mathbf{u}_i = \lambda_i \mathbf{u}_i$$

投影形式为：

$$z_i = \mathbf{u}_i^T (\mathbf{x} - \mu)$$

## K-L / PCA

无监督，目标是保留数据总体方差。

## Fisher

有监督，目标是增强类别可分性。

# 实验三：实验设置与实现

## 设置



- 数据：FEMALE + MALE 共 100 个训练样本
- 特征：身高、体重
- 方法一：不考虑类别信息，做 PCA
- 方法二：利用类均值差方向投影
- 对比：Fisher 与 Gaussian Bayes

## 关键参数

| 项目       | 数值               |
|----------|------------------|
| 第一主成分解释率 | 87.52%           |
| PC1      | (0.6269, 0.7791) |
| 类均值方向    | (0.6514, 0.7587) |



# 实验三：投影方向与样本分布



本数据中最大方差方向与性别差异方向比较接近，因此 PCA 一维投影也能取得较好分类效果。

# 实验三： 结果与分析

| 方法             | 训练集    | test1   | test2  |
|----------------|--------|---------|--------|
| K-L PCA 第一主成分  | 86.00% | 100.00% | 89.67% |
| 类均值方向          | 86.00% | 100.00% | 89.67% |
| Fisher         | 88.00% | 97.14%  | 90.33% |
| Gaussian Bayes | 88.00% | 97.14%  | 89.33% |

## 分析


- K-L 适合降维和特征提取，但不是专门为分类优化
- Fisher 使用类别标签，因此在 test2 上略优
- 当主方差方向与类别差异方向一致时，PCA 也可以获得较好分类效果

# 实验四

K-L 变换在飞机图像识别中的应用

# 实验四：课程理论

图像可以看作高维向量。K-L 变换在图像识别中的典型思想是：



与“特征脸”类似，本实验学习的是飞机图像的主要变化方向。

$$\mathbf{z} = U_k^T (\mathbf{x} - \mu)$$

# 实验四：实验设置与实现

## 数据与预处理


- 数据集：飞机分类图像
- 类别数：16 类
- 训练集：2530 张
- 测试集：636 张
- 预处理：灰度化、缩放到  $32 \times 32$ 、展开为 1024 维向量

## 模型设置


- 标准化后进行 PCA
- 主成分数：8、16、32、64、128
- 分类器：Nearest Centroid 与 1NN
- 主结果：64 维 PCA + 1NN

# 实验四：样本与主成分

Aircraft Dataset Samples



First K-L/PCA Image Components




64 个主成分保留约 89.88% 的训练集方差信息，将 1024 维图像压缩到 64 维。

# 实验四：结果与分析


| 方法                  | 主成分数 | 训练集     | 测试集    |
|---------------------|------|---------|--------|
| PCA+NearestCentroid | 64   | 20.47%  | 19.97% |
| PCA+1NN             | 32   | 100.00% | 54.09% |
| PCA+1NN             | 64   | 100.00% | 53.93% |
| PCA+1NN             | 128  | 100.00% | 52.99% |

## 分析

- 1NN 明显优于最近质心，说明类内变化较复杂
- 主成分过多后，背景和噪声也会被保留
- PCA 是有效特征压缩方法，但单独使用不足以完成高精度图像分类



# 实验四：混淆矩阵观察



## 主要现象

- 部分飞机类别外形相近，在低分辨率灰度图中容易混淆
- 姿态、背景、拍摄尺度会进入 PCA 主成分
- 后续可结合 HOG/SIFT/ORB 或 CNN 提升识别能力



# 实验五


C 均值与分级聚类分析

# 实验五：课程理论

C 均值聚类即 k-means，通过迭代最小化类内平方误差：

$$J = \sum_{j=1}^C \sum_{\mathbf{x}_i \in \omega_j} \|\mathbf{x}_i - \mu_j\|^2$$

迭代步骤：



分级聚类则通过样本间距离形成层次结构，可用树状图观察聚类关系。

# 实验五：实验设置与实现



## 数据设置

- 数据一：FEMALE + MALE, 共 100 个样本
- 数据二：训练集 + test2, 共 400 个样本
- 特征：身高、体重
- 预处理：标准化

## 方法设置


- C 均值：独立编程实现
- 类别数：2、3、4、5
- 初始值：多随机种子比较
- 分级聚类：Ward 方法

## 实验五：C 均值聚类结果




训练集取  $C=2$  时，与真实性别标签的最佳匹配率约为 85.00%；不同初始值下约在 85.00% 到 87.00% 之间波动。

# 实验五：类别数选择与分级聚类



**C 均值, 训练集 C=2**



轮廓系数 0.5108, ARI 0.4850, 性别匹配率 85.00%



**Ward 分级聚类, 训练集 2 类**

轮廓系数 0.5049, ARI 0.3789, 性别匹配率 81.00%

## 实验五：加入 test2 后的变化



加入 test2 后样本变为 400 个，男生比例更高；C=2 的匹配率为 84.50%，整体结构仍然支持两类划分，但边界样本更多。

# 实验五：分析总结

| 数据        | 方法        | 轮廓系数   | ARI    | 性别匹配率  |
|-----------|-----------|--------|--------|--------|
| 训练集       | C 均值, 2 类 | 0.5108 | 0.4850 | 85.00% |
| 训练集       | Ward, 2 类 | 0.5049 | 0.3789 | 81.00% |
| 训练集+test2 | C 均值, 2 类 | 0.4850 | 0.4693 | 84.50% |
| 训练集+test2 | Ward, 2 类 | 0.4739 | 0.4172 | 82.50% |

## 体会

- 聚类不使用标签，但能发现与性别相关的自然分组
- C 均值需要指定类别数，对初始化和特征尺度敏感
- 分级聚类更适合观察层次关系，但大样本计算成本更高

# 五个实验的横向关系

| 实验              | 课程知识点          | 监督信息    | 主要目标             |
|-----------------|----------------|---------|------------------|
| Bayes 分类        | 后验概率、参数估计、风险决策 | 使用标签    | 最小错误率或最小风险       |
| Fisher / Parzen | 非参数估计、线性判别、留一法 | 使用标签    | 比较概率模型与直接判别      |
| K-L 特征提取        | PCA、协方差特征分解    | 可不使用标签  | 降维与主方向分析         |
| K-L 图像应用        | 高维图像特征压缩       | 使用标签做识别 | 验证 PCA 在图像识别中的作用 |
| 聚类分析            | C 均值、分级聚类      | 不使用标签   | 发现样本自然结构         |



# 总体结论

## 实验认识

- 特征选择会直接影响分类器性能
- 先验概率和损失函数体现任务背景
- 非参数方法灵活，但依赖样本和超参数
- K-L 适合降维，不一定最适合分类
- 聚类能揭示结构，但解释需要结合真实标签

核心体会：模式识别方法没有绝对最优，算法选择必须结合数据分布、任务目标和评价指标。

## 课程联系

- 从概率决策到线性判别
- 从监督分类到无监督聚类
- 从低维特征到高维图像识别
- 从训练误差到泛化性能评估

